

# Predição De Gargalos na Transmissão de Vídeo em Redes 5G

Aluno: Josean Mario Moreira Rodrigues (Matrícula: 20189046677)

E-mail: josean.rodrigues@ufpi.edu.br; Período da Graduação: VI

Orientador: Rayner Gomes Sousa

6 de março de 2023

## Resumo

**Contexto:** A quinta geração de telefonia móvel (5G) traz grandes avanços tecnológicos para a qualidade de vida humana, sendo orientada a serviços e abrangendo vários campos, dentre eles: medicina, veículos autônomos e aplicações móveis. As redes 5G serão em grande parte utilizadas para transmissão de vídeo, o que inclui cirurgias remotas e realidade aumentada.

**Problema:** As transmissões de vídeos em redes 5G suportam o uso de Ultra-Alta Definição que inclui vídeos em 4K e 8K, tais definições exigem uma baixa latência e uma maior vazão na transmissão dos dados pela rede. Porém, o 5G não prioriza o *uplink* quando se fala em compartilhamento de rede, em casos que exigem baixa latência como a transmissão de vídeo, essa limitação pode gerar gargalos.

**Proposta:** Desenvolver um algoritmo para analisar os parâmetros da transmissão de vídeo, tais como: latência, estado do usuário final (movimento ou parado), espaço de armazenamento do vídeo em *buffer* e resolução da imagem. O algoritmo será capaz de prever em quais casos acontecem gargalos na transmissão de vídeo. As saídas produzidas pelo algoritmo serão de grande importância para definir se o problema de não priorização de *uplink* na rede 5G pode impactar o serviço de transmissão de forma negativa, como p.ex: assistir vídeos em uma plataforma de *streaming* ou em ambientes críticos que abrangem cirurgia remota e veículos autônomos.

**Palavras-chaves:** 5G, transmissão de vídeo, predição, *uplink*, parâmetros.

## 1 Introdução

O sistema 5G foi introduzido em vários países e tem como principal objetivo ser uma arquitetura inovadora que abrange serviços em diversas áreas. A sua arquitetura é direcionada para o suporte de três tipos de casos de uso, são elas: (1) Banda Larga Móvel Melhorada (*enhanced Mobile Broadband*, eMBB) que diz respeito à banda larga móvel com melhorias; (2) Comunicações Ultra Confiáveis e de Baixa Latência (*ultra Reliable Low Latency Communication*, uRLLC) comunicação ultra confiável com maior vazão de dados e baixa latência; (3) Comunicação Massiva de Máquinas (*massive Machine-Type Communication*, mMTC) que suporta maior demanda de máquinas conectadas (KIMURA; ALMEIDA et al., 2021). Cada um desses casos de usos são constituídos por serviços que

envolvem a transmissão de vídeo, ou seja, a transmissão de vídeo é um serviço ubíquo no sistema 5G.

O 5G introduziu a transmissão de vídeo de baixa latência, sendo incorporada em várias áreas da indústria, a sua confiabilidade de rede sem fio faz com que seja ideal para comunicação entre veículos, monitoramento de pacientes em uma ambulância em movimento e vigilância. No entanto, tais cenários estão sujeitos a problemas na latência de transmissão de vídeo. Cada um dos principais passos de transmissão como captura, codificação, transmissão, decodificação e exibição adicionam algum atraso e a soma destes atrasos é a latência de ponta a ponta. Então, a atenção dada a parâmetros de transmissão de vídeo é essencial (UITTO; HEIKKINEN, 2021).

O sistema 5G é baseado no conceito de programação de toda a infraestrutura de rede (em inglês este conceito é referido como *softwarization*). O conceito implica que a rede, de ponta a ponta, deve ser programável. Para a realização deste conceito o 5G é dependente de três paradigmas: (a) Computação em nuvem: os serviços são mantidos na nuvem; (b) Redes Definidas por *Software*: o comportamento da rede pode ser gerenciado de forma centralizada e novas funções podem ser adicionadas em tempo real; (c) Virtualização de Funções de Rede: todos os serviços são funções encadeadas e distribuídas na rede, o objetivo é que aplicações de rede sejam independentes do *hardware* e dos fabricantes de equipamentos (ORDONEZ-LUCENA et al., 2017).

Em decorrência da programação de rede o 5G pode implantar redes virtuais sob demanda de forma a suportar os três tipos essenciais de casos de usos supracitados (eMBB, uRLLC e mMTC). Desse modo, o sistema 5G é flexível o suficiente para ser programado a fim de potencializar a resolução de problemas enfrentados nas gerações anteriores. Um problema atual, decorrente da herança dos sistemas antigos, é que o sistema telefônico móvel nunca foi projetado para realizar o *streaming* nativamente, como consequência, o sistema não prioriza o *uplink* (canal de envio de dados contínuos do usuário para o sistema). A não priorização é um dos fatores para geração de gargalos na rede, ocasionando problemas em diversas áreas críticas que demandam baixa latência, como por exemplo: cirurgias remotas, veículos autônomos e entrega de dados ambientais em tempo real (UITTO; HEIKKINEN, 2022).

A predição da qualidade do enlace de rede é uma das chaves para melhorar a transmissão de vídeo em redes 5G e em futuras gerações como no 6G (GUI et al., 2020). O uso de inteligência artificial (*Artificial Intelligence*, AI), especialmente o aprendizado de máquina (*Machine Learning*, ML) permitem que as redes móveis como o 5G possam adotar medidas que abrangem previsão e proatividade da rede (WANG et al., 2022). Os aplicativos de *streaming* atuais fornecem altos níveis de qualidade de experiência do usuário (*Quality of Experience*, QoE). Porém, maior qualidade passa a ser um grande desafio, pois a transmissão do usuário pela *Internet* pode estar sujeita a fatores como variação na largura de banda, mobilidade do usuário, variação do atraso de pacotes (*jitter*) e outros. O uso de aprendizado de máquina utilizando uma variedade de parâmetros é necessário para melhorar a estimativa de precisão e portanto a qualidade de transmissão de vídeo (RACA et al., 2019).

## 1.1 Objetivos Gerais e Específicos

O objetivo principal deste projeto é desenvolver uma solução para os problemas da quebra da qualidade das transmissões de *streaming* de vídeo no 5G, por meio das abordagens de ML e IA, a fim de identificar quais combinações de parâmetros podem

gerar gargalos. Assim, contribuindo para que sistemas atuais e futuros possam garantir a qualidade de transmissão de vídeo. Os objetivos específicos deste trabalho são:

1. Identificar quais parâmetros presentes em *streaming* de vídeo podem causar gargalo.
2. Apresentar novas soluções para lidar com o problema de forma mais eficaz.
3. Melhorar a capacidade do sistema 5G em lidar com transmissões de vídeo.

## 2 Justificativa

A *Ooredoo* empresa multinacional de telecomunicações do Catar que foi selecionada pela FIFA como provedora oficial de serviços de conectividade para cobrir a copa do mundo em 2022, em parceria com a empresa Sueca *Ericsson*, cobriram serviços 5G em *fan zones*, estádios, aeroportos e principais atrações turísticas (SMITH, 2022). Assim possibilitando que as pessoas pudessem assistir aos jogos da copa, a partir de transmissão de vídeo de alta qualidade. Como resultado da implementação da rede 5G em suas principais áreas, o Catar registrou a melhor conexão móvel global no mês de novembro de 2022 (SPEEDTEST, 2022).

Considerando um futuro próximo, a (CISCO, 2022) disponibilizou uma série de pesquisas que apontam que até 2023 haverá mais de 13,1 bilhões dos dispositivos conectados na Internet por meio do 5G, isso representa mais do que de 10% dos dispositivos móveis globais atuais. Por exemplo, carros com condução autônoma são cobertos pelo sistema 5G. A assistência remota de direção oferece mais flexibilidade do que permitir que o veículo seja controlado por uma única IA unicamente. Destaca-se que veículos controlados remotamente a latência entre o veículo e o controlador remoto passa a depender da transmissão de vídeo e dos protocolos empregados para transmissão. A latência da rede, o *jitter* e a qualidade da transmissão de vídeo, por exemplo vídeos em ultra alta definição (*Ultra-High Definition*, UHD) que implicam em uma resolução de imagem com no mínimo  $3.840 \times 2.160$  *pixels*, são alguns dos desafios para o controle de veículo em tempo real, qualquer esforço que possa reduzir a latência é um aspecto muito importante (YU; LEE, 2022).

O formato de vídeo UHD é uma das demandas dos usuários quando se aborda o tema *streaming* de vídeo em redes 5G. Por esta razão, a criação de modelos que possam prever a qualidade de vídeo baseado nas suas características e configurações de codificação é essencial. O uso de ML oferece as técnicas factíveis para que os dados extraídos possam ser processados de modo a extrair informações de modo a identificar padrões que possam prever a qualidade do conteúdo audiovisual, resultando na melhora da qualidade de transmissão (LÓPEZ et al., 2018).

No momento da escrita desta obra, ainda existem poucas bases de dados com parâmetros de *streaming* de vídeo em rede 5G, a maior delas encontrada até então é apresentada por (QUINLAN et al., 2020). Apesar das poucas bases de dados disponíveis, existem várias obras que utilizam a base citada acima, como as apresentadas por (KIMURA; ALMEIDA et al., 2021), (MUSTAFA et al., 2020), (MUSTAFA; MOURA; ROTHENBERG, 2021), (MEHMETI; PORTA, 2021) e (GAO, 2022). Portanto, evidenciando a importância de contemporaneidade do tema.

### 3 Referencial Teórico

Esta seção descreve conceitos importantes para o entendimento deste projeto. As seções incluem conceitos sobre a Quinta Geração de Telefonia Móvel (3.1), *Streaming* de vídeo (3.2), Qualidade de experiência do usuário e Qualidade de Serviço (3.2.1), Aprendizado de máquina (3.3).

#### 3.1 Quinta Geração de Telefonia Móvel (5G)

A Quinta Geração de Telefonia Móvel (5G) é a mais recente sistema de telecomunicação desenvolvida, o qual seu projeto e especificações ficam sobre responsabilidade da *International Telecommunication Union* (ITU) e *Third Generation Partnership Project* (3GPP). Espera-se que os sistema atinja taxas de dados entre 10 *Gbit/s* e 20 *Gbit/s*, com latência de 1 ms de ponta a ponta.

O 5G é um sistema vital para serviços emergentes, que envolvem condução autônoma, realidade virtual, realidade aumentada e jogos móveis (FENG; YUAN; QIU, 2022). No 5G a rede é baseada na virtualização da rede e dos serviços que são disponibilizados para cada usuário, na nomenclatura do 5G essas redes virtuais são chamadas de fatias de rede (SRIRAAM et al., 2020). As fatias possibilitam que as aplicações não sejam dependentes do *hardware*, como ocorre na versão anterior do 5G, a saber, a rede de quarta geração (4G). Os benefícios do fatiamento de rede consiste no maior controle e flexibilidade no manejo dos serviços ofertados.

(ZHAO et al., 2022) cita que o 5G, apesar de ser uma tecnologia que traz bastantes benefícios, o custo para a construção deste tipo de rede é enorme, o que aumenta com a densa cobertura e os altos requisitos para a distribuição, como consequência, a modelagem e ambientes de simulação se mostram atraentes para estudos no contexto do 5G.

#### 3.2 *Streaming* de vídeo

*Streaming* é a distribuição de conteúdos multimídia na rede, o que inclui música, vídeo e outros. Funciona através do *download* do conteúdo em um *buffer* no dispositivo do usuário, que ocorre durante a transmissão. O *streaming* de vídeo está impactando não apenas no consumo, mas também na criação e distribuição de conteúdo. A transmissão de *streaming* pode ser feita de duas formas, que são elas: sobre demanda e ao vivo. Na transmissão por demanda o conteúdo é criado e salvo em um servidor, então os clientes podem acessar este conteúdo sempre que desejarem, enquanto que ao vivo o conteúdo é criado em tempo real, geralmente *streaming* de vídeo ao vivo é caracterizado pela interação entre o criador de conteúdo e os consumidores por meio de bate-papos (BAENA et al., 2022). Nessa segunda forma, o canal de *uplink* se mostra um ponto chave para sucesso das transmissões em tempo real, uma vez que historicamente são os canais de *uplink* os mais limitados, uma vez que o padrão de transmissão consiste em maior banda nos canais de *downlink*.

De acordo com o (CLOUDFLARE, 2022), as principais etapas que ocorrem durante a transmissão de vídeo ao vivo são: (1) Captura de vídeo; (2) Compactação; (3) Codificação; (4) Segmentação e Distribuição; (5) Decodificação e reprodução do vídeo. Na etapa 1 o vídeo é capturado por uma câmera externa ou pelo próprio dispositivo do usuário, estas informações visuais capturadas são representadas por dados digitais, assumindo valores binários de 0 e 1. Na etapa 2 o vídeo é compactado, removendo informações redundantes,

estas informações redundantes podem ser algum objeto visual que seja estático, assim, este objeto não precisa ser renderizado em todos os quadros subsequentes.

Continuando, Na etapa 3 o vídeo é codificado em formato digital interpretável, geralmente algum reconhecido. Como por exemplo: H.264, VP9, AV1. Na etapa 4 o vídeo é dividido em segmentos com duração de alguns segundos, que são enviados para uma rede de distribuição de conteúdo (*Content Delivery Network*, CDN), que por sua vez armazena estes segmentos em *cache*. A ideia por trás de uma CDN é fazer com que o usuário consuma estes segmentos sem ter que fazer a solicitação diretamente no servidor de origem, resultando no desempenho substancial da transmissão. Por fim, na etapa 5, o usuário recebe o segmento, o seu dispositivo faz a decodificação e descompactação. Então o reprodutor de mídia é utilizado, que pode ser um aplicativo específico ou o próprio navegador.

### 3.2.1 Qualidade experiência do usuário (*Quality of Experience*, QoE) e Qualidade de Serviço (*Quality of Service*, QoS)

Qualidade de Experiência (QoE) é originada do termo Qualidade de Serviço (QoS). Tem como objetivo melhorar a percepção do usuário sobre o conteúdo que ele recebe, como por exemplo algoritmos de *Adaptive Bitrate Streaming* (ABS), que de acordo com a qualidade da *Internet* fazem a conversão de qualidade de vídeo, evitando assim que o vídeo sofra por interrupções (MUSTAFA et al., 2020). De acordo com (SAOVAPAKHIRAN et al., 2022) o QoE também pode ser visto como a forma que o usuário se sente bem ou aborrecido com determinado serviço ou aplicativo.

Qualidade de Serviço (QoS) tem como objetivo o melhorar o serviço ofertado. O QoS desempenha um papel fundamental na manutenção de serviços na *Internet*. Visando melhorar os critérios de otimização da rede, qualidade da rede, consumo de energia e outros. Sendo assim, as métricas de QoS são fatores indispensáveis e que tem impacto direto na experiência do usuário (SAOVAPAKHIRAN et al., 2022). Na prática o QoE é construído através da aplicação de QoS em vários elos do sistema. Por exemplo, o QoS em redes de computadores é aplicado através da classificação de pacotes e por política de filas.

O QoS e o QoE são métodos essenciais para a avaliação de *streaming* de vídeo em redes 5G. De acordo com (CHEN; WU; ZHANG, 2015), a avaliação de *streaming* de vídeo evoluiu de uma avaliação centrada no QoS para uma avaliação mais centrada no QoE. Esta tendência é muito por conta da demanda do usuário por serviços e vídeo, o que torna a criação de modelos de QoE que possam monitorar, prever e controlar um fator importante, que impacta de forma positiva provedores de serviços e operadoras de rede.

## 3.3 Aprendizado de Máquina

Aprendizado de máquina são técnicas computacionais que permitem que um programa de computador adquira conhecimento de forma automática, e que baseada em experiências anteriores possa tomar decisões de forma precisa (MONARD; BARANAUSKAS, 2003). A inteligência artificial está avançando muito rápido, as máquinas já conseguem realizar trabalhos manuais e tarefas que exigem raciocínio lógico, como por exemplo: condução de veículos não tripulados, automação de diagnósticos médicos e aplicação em tradutores como o do *Google* (LUDERMIR, 2021).

O aprendizado de máquina pode ser classificado como supervisionado e não supervisionado. No aprendizado de máquina supervisionado, o algoritmo possui conhecimento prévio dos rótulos dos dados. Fazendo comparações entre os rótulos previamente classifica-

dos e os resultados obtidos com o modelo de classificação. O algoritmo é repetido até que a acurácia desejada seja alcançada.

Enquanto que no aprendizado não supervisionado, o algoritmo extrai as características sem o conhecimento prévio dos rótulos e constrói uma representação, assim identificando heurísticamente os padrões de classificação, ou seja, exige menos interferência humana para que se chegue no resultado preciso (PAIXÃO et al., 2022).

## 4 Trabalhos Relacionados

Nesta seção, serão apresentados os trabalhos que se relacionam com esta obra e têm alguma relevância. A Tabela 1 apresenta um resumo comparativo dos trabalhos relacionados em 3 aspectos: *Streaming* em redes 5G, Utiliza ML, Foco em gargalos. Artigos que estavam no contexto de *streaming* de vídeo em redes 5G foram o principal objetivo, pois o projeto desenvolvido tem ele como tema central. Em seguida artigos que utilizaram ML para solucionar problemas no contexto de *streaming*, a solução que será apresentada neste trabalho utiliza ML. Como objetivo final, foi dada importância para trabalhos que estivessem no contexto de gargalos em *streaming* de vídeo, nenhuma das obras citadas tem este problema como foco principal, algumas abordam problemas em *streaming* de maneira mais abrangente ou com foco em outros problemas.

Tabela 1 – Trabalhos Relacionados

Trabalhos relacionados	<i>Streaming</i> em 5G	Utiliza ML	Foco em gargalos
(KIMURA; ALMEIDA et al., 2021)	Sim	Sim	Não
(MUSTAFA et al., 2020)	Sim	Sim	Não
(MUSTAFA; MOURA; ROTHENBERG, 2021)	Sim	Sim	Não
(MEHMETI; PORTA, 2021)	Sim	Não	Não
(GAO, 2022)	Sim	Sim	Não
(QUINLAN et al., 2020)	Sim	Não	Não
(BAENA et al., 2022)	Sim	Não	Não
Este trabalho	Sim	Sim	Sim

Os trabalhos de (QUINLAN et al., 2020) e (BAENA et al., 2022) são semelhantes, pois apresentam bases de dados para serem usadas em pesquisas posteriores. No trabalho de (QUINLAN et al., 2020), é apresentado um conjunto de dados no contexto do 5G, os dados foram coletados de uma operadora móvel Irlandesa. Os dados são gerados de duas maneiras: estática e em movimento (utilizando carro). Com 2 tipos de padrões: *streaming* de vídeo e *download* de um arquivo. Sendo o conjunto de dados composto com os principais indicadores de desempenho (KPI). Enquanto que no trabalho de (BAENA et al., 2022), é apresentada uma base de dados com várias métricas chaves de indicadores de qualidade (KQI). Os serviços considerados nestes dados são *streaming* de vídeo e jogos em nuvem. O autor também faz uma descrição detalhada do *testbed* em que os dados foram gerados, discutindo as ideias por trás das escolhas para o seu desenvolvimento.

Os trabalhos de (KIMURA; ALMEIDA et al., 2021), (MUSTAFA et al., 2020), (MUSTAFA; MOURA; ROTHENBERG, 2021), (MEHMETI; PORTA, 2021), (GAO, 2022) e este trabalho utilizam a base de dados apresentada por (QUINLAN et al., 2020). Nos parágrafos seguintes será apresentado um resumo das principais contribuições que foram realizadas em cada um dos trabalhos mencionados acima.

No trabalho de (KIMURA; ALMEIDA et al., 2021) ele propõem uma nova abordagem de ML para realizar previsões em redes 5G. Ele fez isso transformando as séries



temporais de informações de rede em imagens, obtendo assim uma representação bidimensional. As diferentes técnicas utilizadas foram: campos de transição de Markov (MTF), gráficos de recorrência (RP) e campos angulares de Gramian (GAF).

Os trabalhos de (MUSTAFA et al., 2020) e (MUSTAFA; MOURA; ROTHENBERG, 2021) foram produzidos na mesma universidade e com alguns dos mesmos pesquisadores em ambas as obras, porém, com foco diferente. No trabalho de (MUSTAFA et al., 2020) ele propôs duas contribuições. A primeira delas foi analisar o estado da arte de algoritmos ABS, variando as chaves de QoS em cenários estáticos e móveis. Em segundo lugar uma comparação de relacionamento entre cinco modelos de QoE, três parâmetros de QoS e sete Indicadores-chave de desempenho (KPI) de diferentes vídeos. Enquanto que no trabalho de (MUSTAFA; MOURA; ROTHENBERG, 2021), foram examinados recursos reais de QoS criptografados derivados de uma rede 5G com o objetivo de estimar indicadores de QoE. Foram selecionados o estado da arte de três algoritmos ABS que são: Híbrido – Elástico, *Buffered* – BBA e Tarifário – Convencional. Em seguida, foi proposto um classificador de aprendizado de máquina para estimar o QoE, este classificador conseguiu alcançar precisão de 91%.

O trabalho de (MEHMETI; PORTA, 2021), focou em analisar um conjunto de dados de *streaming* de vídeo em 5G, a análise foi conduzida separadamente entre dados estáticos e móveis. As contribuições desta obra foram: caracterizar a distribuição de taxas de dados utilizando funções de distribuição, caracterizar a qualidade de canal em *streaming* móvel e estático e quais as transições mais prováveis de um estado do canal para outro estado.

(GAO, 2022) apresentou um modelo que faz a previsão precisa da rede 5G, baseado no modelo *Smoothed Long Short Term Memory* (SLSTM). Os resultados mostraram que o algoritmo SLSTM pode melhorar a precisão da previsão do tráfego no 5G de maneira efetiva. Além disso, comparando o método proposto no artigo com outros métodos, foi constatado que o modelo do autor mostrou maior grau de ajuste, menor grau de erro e previsão mais precisa. Porém, os fatores que possam afetar o tráfego como gargalos não são considerados de forma abrangente.

Este trabalho propõe utilizar um conjunto de dados no contexto de *streaming* de vídeo em 5G. Desenvolver um algoritmo capaz analisar os parâmetros da transmissão de vídeo como latência, armazenamento em *buffer*, resolução e outros. O trabalho desenvolvido será capaz de prever em quais casos acontecem gargalos na rede, a contribuição deste trabalho é importante, pois os resultados podem ser utilizados para futuras melhorias na futura rede 6G.

## 5 Esboço da Proposta

Como proposta, este trabalho concebe bases para o desenvolvimento de uma solução para identificar e tratar gargalos em *streaming* de vídeo em um sistema segundo a infraestrutura do 5G, especialmente considerando sua estrutura e a forma de como a provisão e o gerenciamento de serviços e recursos são realizados. A importância da transmissão de vídeo é evidente uma vez que ela é intrínseca nos três tipos básicos de comunicação (mMTC, URLLC e eMBB) presentes no 5G. O desafio é inerente à forma com os sistemas 5G lidam com o *streaming*, cujas aplicações exigem o controle constante da baixa latência a fim de suportar vídeo 4K e 8K e com taxa acima dos 30fps. segundo.

Entre as bases fundamentais de nossa proposta é a adoção do aprendizado de

máquina para proceder a técnica de regressão de forma a detectar quais casos potenciais de acontecimentos futuros de gargalos em *streaming* de vídeo analisando a relação das variáveis: latência, *jitter*, taxa de transferência, vazão e codificação de vídeo. O conjunto de dados extraídos de (QUINLAN et al., 2020) permitirão alimentar o aprendizado de máquina com dados utilizados pela comunidade científica em trabalhos afins.

A utilização de regressão com *machine learning* para resolver o problema de gargalos no 5G é um passo inovador, pois analisar manualmente quais passos conduzem a rede a ter este tipo de problema é inviável, então buscar maneiras mais eficientes que gerem resultados precisos e que possam em um futuro próximo serem utilizadas como base na identificação deste tipo de problema, exprime a importância do tema.

## 6 Metodologia e Cronograma

A Figura 6 apresenta um modelo baseado em Linguagem de Modelagem Unificada (*Unified Modeling Language*, UML) que mostra a metodologia adotada neste trabalho. A figura aponta atividades inseridas no cronograma de planejamento. A metodologia planejada deste trabalho é composta em 9 etapas que são: (i) Definição do tema, (ii) Definição das palavras chaves, (iii) Levantamento bibliográfico, (iv) Extração das características, (v) Desenvolvimento do projeto, (vi) Experimento, (vii) Análise dos resultados, (viii) Redação da monografia e (ix) Apresentação da monografia.

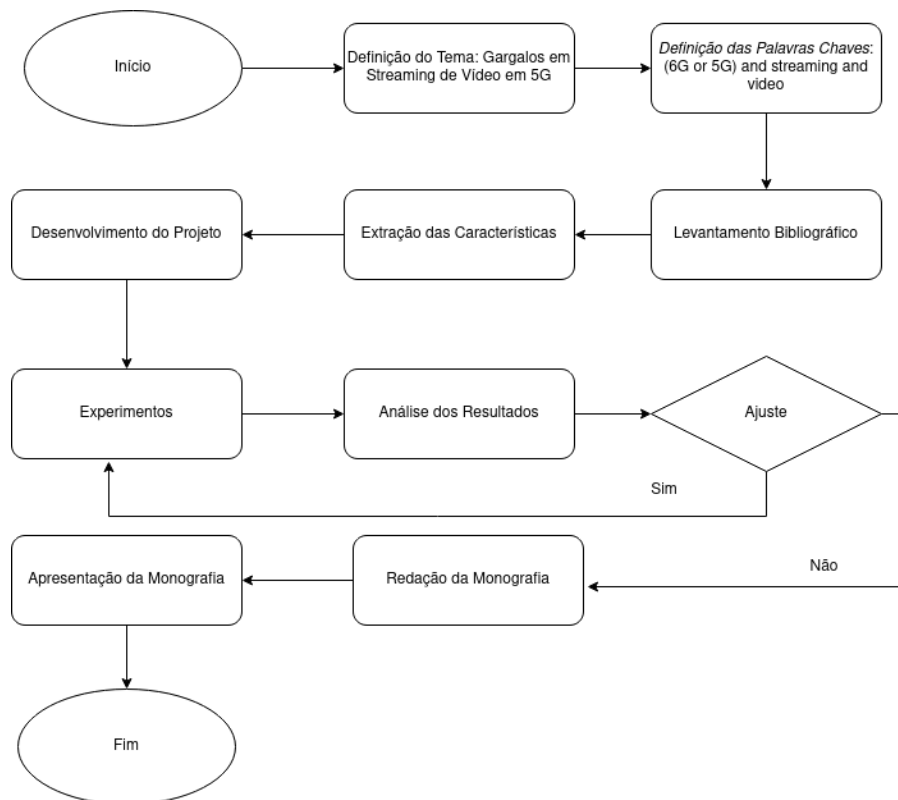


Figura 1 – Metodologia do Projeto.

1. Definição do Tema: Nesta etapa, anterior a escrita deste documento, compreendeu a escolha do tema do trabalho, levando em conta fatores como viabilidade de



desenvolvimento do projeto e inovação para a área.

2. Definição das palavras chaves: Esta etapa é uma atividade crucial para o sucesso do projeto, pois as palavras chaves são guias para a correta coleta de artigos utilizados como fundamentação teórica.
3. Pesquisa Bibliográfica: Atividade que compreende a identificação, localização, compilação e a extração das informações e ideias mais importantes de nossa pesquisa. A obtenção de informações relevantes do tema escolhido na etapa 1. A base de dados a qual as palavras chaves são inseridas e a qualidade dos artigos obtidos são críticos para o desenvolvimento do projeto, também nesta etapa é realizada a filtragem, a primeira etapa da filtragem consiste na leitura do título e resumo, a segunda etapa consiste em ler o artigo completo.
4. Extração das características: Nesta etapa são extraídas as características da base de dados que será utilizada para a resolução do problema.
5. Desenvolvimento do projeto: Nesta etapa inicia-se o desenvolvimento do projeto, como escolher modelo de resolução, a linguagem de programação e plataformas de desenvolvimento.
6. Experimentos: Nesta etapa os experimentos são executados, objetiva-se aplicar a solução proposta.
7. Análise de resultados: Após finalizar a etapa anterior, esta etapa compreende a examinação minuciosa e detalhada dos resultados obtidos no experimentos, caso a ineficácia da solução, a etapa de Experimentos será repetida com os devidos aprimoramentos.
8. Redação da monografia: Nesta etapa serão redigidas as seções que compreendem a natureza deste trabalho e de todo o seu invólucro contextual, segundo as regras e formatos que compõem um trabalho de conclusão de curso.
9. Apresentação da monografia: Nesta etapa será apresentado o trabalho perante a banca.

Por fim, a Tabela 2 apresenta o cronograma planejado para a execução do projeto de forma detalhada.

Tabela 2 – Cronograma para desenvolvimento do projeto

Etapas em Meses	1-2	3-4	5-6	7-8	9-10	11-12
Levantamento Bibliográfico						X
Extração das Características	X					
Desenvolvimento do Projeto			X	X	X	
Análise dos Resultados			X			
Redação da Monografia	X	X				X
Apresentação da Monografia		X				X

## Referências

- BAENA, C. et al. Video streaming and cloud gaming services over 4g and 5g: a complete network and service metrics dataset. TechRxiv, 2022. Citado 2 vezes nas páginas 4 e 6.
- CHEN, Y.; WU, K.; ZHANG, Q. From qos to qoe: A tutorial on video quality assessment. *IEEE Communications Surveys Tutorials*, v. 17, n. 2, p. 1126–1165, 2015. Citado na página 5.
- CISCO. *Cisco Annual Internet Report (2018–2023) White Paper*. 2022. Disponível em: <<https://www.cisco.com/c/en/us/solutions/collateral/executive-perspectives/annual-internet-report/white-paper-c11-741490.html>>. Acesso em: 18 dez. 2022. Citado na página 3.
- CLOUDFLARE. *O que é streaming ao vivo? | Como funciona o streaming ao vivo*. 2022. Disponível em: <<https://www.cloudflare.com/pt-br/learning/video/what-is-live-streaming/>>. Acesso em: 23 dez. 2022. Citado na página 4.
- FENG, X.; YUAN, S.; QIU, S. For high frequency 5g analysis and predictions for large video surveillance systems. In: *2022 IEEE 2nd International Conference on Electronic Technology, Communication and Information (ICETCI)*. [S.l.: s.n.], 2022. p. 1072–1075. Citado na página 4.
- GAO, Z. 5g traffic prediction based on deep learning. *Computational Intelligence and Neuroscience*, Hindawi, v. 2022, 2022. Citado 3 vezes nas páginas 3, 6 e 7.
- GUI, G. et al. 6g: Opening new horizons for integration of comfort, security, and intelligence. *IEEE Wireless Communications*, IEEE, v. 27, p. 126–132, 2020. ISSN 15580687. Citado na página 2.
- KIMURA, B. Y. L.; ALMEIDA, J. et al. Deep learning in beyond 5g networks with image-based time-series representation. *arXiv e-prints*, p. arXiv–2104, 2021. Citado 3 vezes nas páginas 1, 3 e 6.
- LUDERMIR, T. B. Inteligência artificial e aprendizado de máquina: estado atual e tendências. *Estudos Avançados*, SciELO Brasil, v. 35, p. 85–94, 2021. Citado na página 5.
- LÓPEZ, J. P. et al. Prediction and modeling for no-reference video quality assessment based on machine learning. In: *2018 14th International Conference on Signal-Image Technology Internet-Based Systems (SITIS)*. [S.l.: s.n.], 2018. p. 56–63. Citado na página 3.
- MEHMETI, F.; PORTA, T. F. L. Analyzing a 5g dataset and modeling metrics of interest. In: *2021 17th International Conference on Mobility, Sensing and Networking (MSN)*. [S.l.: s.n.], 2021. p. 81–88. Citado 3 vezes nas páginas 3, 6 e 7.
- MONARD, M. C.; BARANAUSKAS, J. A. Conceitos sobre aprendizado de máquina. *Sistemas inteligentes-Fundamentos e aplicações*, Manole, v. 1, n. 1, p. 32, 2003. Citado na página 5.

MUSTAFA, R. U. et al. Dash qoe performance evaluation framework with 5g datasets. In: IEEE. *2020 16th International Conference on Network and Service Management (CNSM)*. [S.l.], 2020. p. 1–6. Citado 4 vezes nas páginas 3, 5, 6 e 7.

MUSTAFA, R. U.; MOURA, D.; ROTHENBERG, C. E. Machine learning approach to estimate video qoe of encrypted dash traffic in 5g networks. In: *2021 IEEE Statistical Signal Processing Workshop (SSP)*. [S.l.: s.n.], 2021. p. 586–589. Citado 3 vezes nas páginas 3, 6 e 7.

ORDONEZ-LUCENA, J. et al. Network slicing for 5g with sdn/nfv: Concepts, architectures, and challenges. *IEEE Communications Magazine*, v. 55, 2017. ISSN 01636804. Citado na página 2.

PAIXÃO, G. M. de M. et al. Machine learning na medicina: Revisão e aplicabilidade. *Arquivos Brasileiros de Cardiologia*, Sociedade Brasileira de Cardiologia, v. 118, n. 1, p. 95, 2022. Citado na página 6.

QUINLAN, J. et al. Beyond throughput, the next generation: a 5g dataset with channel and context metrics. In: . [S.l.: s.n.], 2020. Citado 3 vezes nas páginas 3, 6 e 8.

RACA, D. et al. Empowering video players in cellular: Throughput prediction from radio network measurements. In: *Proceedings of the 10th ACM Multimedia Systems Conference*. [S.l.: s.n.], 2019. p. 201–212. Citado na página 2.

SAOVAPAKHIRAN, B. et al. Qoe-driven iot architecture: A comprehensive review on system and resource management. *IEEE Access*, v. 10, p. 84579–84621, 2022. Citado na página 5.

SMITH, J. S. *Qatar Scores Big with 5G Network at World Cup*. 2022. Disponível em: <<https://insidetowers.com/qatar-scores-big-with-5g-network-at-world-cup/>>. Acesso em: 18 dez. 2022. Citado na página 3.

SPEEDTEST. *Speedtest Global Index*. 2022. Disponível em: <<https://www.speedtest.net/global-index>>. Acesso em: 18 dez. 2022. Citado na página 3.

SRIRAAM, S. et al. Implementation of 5g authentication and key agreement protocol on xbee networks. In: *2020 International Conference on COMMunication Systems NETWORKS (COMSNETS)*. [S.l.: s.n.], 2020. p. 696–698. Citado na página 4.

UITTO, M.; HEIKKINEN, A. Evaluation of live video streaming performance for low latency use cases in 5g. In: IEEE. *2021 Joint European Conference on Networks and Communications & 6G Summit (EuCNC/6G Summit)*. [S.l.], 2021. p. 431–436. Citado na página 2.

UITTO, M.; HEIKKINEN, A. Evaluating 5g uplink performance in low latency video streaming. In: *2022 Joint European Conference on Networks and Communications 6G Summit (EuCNC/6G Summit)*. [S.l.: s.n.], 2022. p. 393–398. Citado na página 2.

WANG, Y. et al. Qoe-driven link quality prediction for video streaming in mobile networks. In: *2022 IEEE 95th Vehicular Technology Conference: (VTC2022-Spring)*. [S.l.: s.n.], 2022. p. 1–5. Citado na página 2.

YU, Y.; LEE, S. Remote driving control with real-time video streaming over wireless networks: Design and evaluation. *IEEE Access*, v. 10, p. 64920–64932, 2022. Citado na página 3.

ZHAO, X. et al. Multi independent logical cells under 5g radio access network sharing of mobile operators. In: *2022 IEEE International Symposium on Broadband Multimedia Systems and Broadcasting (BMSB)*. [S.l.: s.n.], 2022. p. 1–5. Citado na página [4](#).

## Avaliação Final de TCC 01

ESTE DOCUMENTO DEVE SER PREENCHIDO PELO PROFESSOR AVALIADOR.

Este formulário será entregue junto com o pré-projeto impresso. Tal avaliação mais detalhada ajudará o aluno a evoluir seu trabalho futuro.

Professor, favor preencher antes da defesa apenas os nomes e a tabela de Avaliação Sobre o Documento.

**Marque com um X a opção que melhor corresponde à sua avaliação.**

**Avaliação Sobre o Documento:**

PARTE AVALIADA	RUIM	BOM	ÓTIMO
RESUMO			
INTRODUÇÃO			
OBJETIVOS			
REFERENCIAL TEÓRICO			
TRABALHOS RELACIONADOS			
PROPOSTA			
AVALIAÇÃO			
CRONOGRAMA			
ESCRITA EM GERAL			

**Avaliação Sobre a Apresentação:**

PARTE AVALIADA	RUIM	BOM	ÓTIMO
SEGURANÇA			
CLAREZA DE ARGUMENTAÇÃO			
TEMPO DE APRESENTAÇÃO			
SLIDES			

Nota :